AI가 검토하면 믿을 수 있는가: 대규모 언어모델 자기검토의 효과와 성립 조건에 관한 문헌 검토

이규현

초록

본 검토는 "AI가 만든 결과물은 AI에게 다시 검토시키면 믿을 수 있다"는 통념을 2022~2026년 발표 41편(동료심사 32편)의 본문 수치로 검증했다. 추론 시점에 추가 훈련 없이 같은 모델이 외부 근거 없이 제자리에서 자기 출력을 수정하면 정답 검증 가능 과제에서 정확도가 대체로 떨어지고, 긍정 결과의 상당수는 오라클 누출·약한 베이스라인·측정 방식의 산물이었다. 같은 모델이 평가자가 되면 자기 선호와 위치 편향이 구조적으로 끼어들며 '사람과 n% 일치'는 지표에 민감했다. 반면 실행·테스트·검색·사람 라벨 검증기 같은 모델 밖의 신호나 다른 분포의 검토자가 더해지면 일관되게 개선되고, 사람의 결합도 결과 피드백과 불일치 이연 설계가 있을 때만 이득이었다. 통념은 검토 신호의 출처, 과제 유형, 검토자와 생성자의 유사도에 따라 조건부로만 성립한다.

제1장 서론

제1절 배경과 목적

"AI가 만든 결과물은 AI에게 다시 검토시키면 믿을 수 있다"는 말은 이제 상식처럼 쓰인다. 초안을 쓴 모델에게 다시 확인하라고 시키고, 글의 채점을 모델에게 맡긴다. 필자는 로컬 AI 연구 비서를 운영하며 모델의 자기 판정이 사후 검증에서 세 차례 뒤집히는 경험을 했고, 이것이 개인 사례인지 문헌이 확인한 일반 현상인지가 이 검토의 출발점이다. 연구 질문은 다음과 같다. 추론 시점에 추가 훈련 없이, 생성한 모델과 같은 대규모 언어모델이 자기 출력(추론·코드·서술)을 제자리에서 다시 검토·수정할 때, 검토하지 않은 경우와 비교해 외부 근거 없이도 정답률(검증 가능 과제)과 사람 평가 일치도(열린 과제)가 올라가는가, 그리고 어떤 외부 신호가 더해질 때 결과가 달라지는가. '자기검토'는 생성 모델이 자기 출력을 비평·수정·채점하는 모든 절차, '내재적 자기수정'은 외부 도구·정답·사람 없이 모델 자신의 피드백만 쓰는 경우, '외부 근거'는 실행 결과·검색·사람 피드백·별도 검증기처럼 모델 밖에서 오는 신호를 가리킨다. 제2장은 이 질문을 세 절로 나눠 비교하고, 제3장에서 논의하며, 제4장에서 결론을 적는다.

제2절 검토한 문헌과 방법

문헌 검색은 2026년 10월 28일 라이너 스콜라(scholar.liner.com)의 학술·웹 검색으로 수행했고, 사람+AI 협업 주제는 PubMed를 병행했다(결과 0건). 발행 기간은 2022~2026년, 검색어는 영어다. 절차는 네 단계다. 첫째, /brainstorm-ideas로 연구 질문 후보 3개를 만들고 채팅으로 문헌으로 답할 수 있는지 확인해 질문을 '추론 시점·무훈련·동일 모델·제자리 수정'으로 좁혔다. 둘째, /find-related-papers 6회(종설, 지지 결과, 반대 결과, 평가자 편향, 외부 근거 결합, 사람+AI 메타분석)와 시드 문헌 11편 대조로 비교표 8개(중복 포함 154행)를 만들었다. 주요 검색어는 "survey self-correction large language models", "Large Language Models are not Fair Evaluators position bias" 등이다. 셋째, 대규모 언어모델의 검토·수정·채점 개입을 '검토 없음' 또는 '외부 근거' 조건과 비교한 실증 연구와 이를 종합한 종설·메타분석을 포함하고, 전통 자동평가 지표만 다룬 연구, 사람 평가나 정답 기준이 없는 리더보드, 자기검토와 무관한 훈련 기법은 제외해 41편(동료심

사 32편, 프리프린트 9편)을 선정했다. 넷째, 41편의 본문 표·그림을 스콜라 채팅으로 읽어 수치의 위치를 기록했고, 스콜라에 본문 색인이 없던 7편은 arXiv 원문으로, 출판 정보 10건은 웹 검색으로 확인·교정했으며, 본문을 확인하지 못한 1편(Eriksson et al., 2026)은 초록 기준으로만 인용했다. 구조화에는 /visualize-topic과 연구 공백 검증 채팅을, 초안에는 /write-draft와 문서 편집을, 인용 정리와 최종 점검에는 /add-citations와 /review-document를 썼고, 그림 1은 /generate-figures 초안을 확정 수치로 다시 그려 넣었다. 필자는 연구 질문 설계, 스콜라 프롬프트 작성, 스콜라 출력의 수치·출판 정보 검증, 초안 교정에 Anthropic의 Claude를 보조 도구로 사용했다. 모든 수치는 원문의 표·그림과 대조했으며 판단과 문장의 책임은 필자에게 있다.

제2장 주제별 분석

제1절 외부 근거 없는 자기수정은 효과가 있는가

이 절의 질문은 추론 시점에 추가 훈련 없이, 생성한 모델과 같은 언어모델이 자기 출력을 제자리에서 다시 검토·수정할 때 외부 근거 없이도 정답률이 오르는가이다.

1.1 제자리 수정은 정답 검증 과제에서 대체로 정확도를 떨어뜨린다

정답을 검증할 수 있는 과제에서 제자리 수정의 순이득은 일관되게 음수다. 내재적 자기수정 후 GPT-3.5는 GSM8K 75.9→74.7, CommonSenseQA 75.8→38.1로 하락했고, 오라클 라벨을 준 설정에서만 75.9→84.3으로 올랐다(Huang et al., 2024). GPT-4의 자기 비평도 Game of 24 5%→3% 등 세 과제에서 성능을 떨어뜨렸으나 외부 검증기를 붙이면 회복했고(Stechly et al., 2024), 동일 예산에서 코드 자기수리의 이득은 미미한 반면 사람 피드백은 성공률을 1.58배 올렸다(Olausson et al., 2024).

반복해도 회복되지 않는다. 4회 반복 후 7개 모델 중 4개가 하락했고(Liu & Meng, 2026), 34개 모델·1,000문항에서 자기 정제 성공률은 최고 31.3%였다(Lee et al., 2026). 정답→오답 전환은 Llama-3.1-8B에서 58.8%에 이르는데, 원인은 능력 부족보다 수정 프롬프트에 대한 최근성 편향이어서 원 질문을 반복 제시하는 것만으로 전환이 5.3~10.9%p 줄었다(Zhang et al., 2025).

1.2 절차를 쪼개거나 후보를 고르면 이득이 나나 '수정'과는 다른 기제다

개선이 보고된 사례의 기제는 오류를 고치는 것이 아니라 검증 절차의 분해와 후보 선택이다. ProCo는 질문의 핵심 조건을 가린 검증 문제를 스스로 풀어 답을 대조해 GSM8K 87.1(Self-Correct 75.1)을 기록했고(Wu et al., 2024), SelfCheck는 풀이 전체를 한 번에 검증하면 무작위 수준(55.0%)이나 단계별 재생성·비교와 저신뢰 필터링으로 GSM8K 정답 비율을 67.5→76.5%로 올렸다(Miao et al., 2024). 이득은 옳은 후보를 골라내는 선택에서 나오지 오류를 고치는 능력의 증거가 아니다.

Self-Refine의 5~40%p 개선도 수학에서는 피드백의 94%가 'everything looks good'이었고(Madaan et al., 2023), SelfCheckGPT의 환각 검지(Pearson 78.32)는 찾음이지 고침이 아니다(Manakul et al., 2023). 다만 계획 과제에서 내재적 자기 비평만으로 Blocksworld 49.8→85.5%를 보고한 연구(Bohnet et al., 2025)는 Stechly et al.(2024)과 정면 충돌하며, 차이 후보인 PDDL 도메인 정의 명시의 인과 역할은 추가 확인이 필요하다.

1.3 부정 결과의 상당 부분은 측정과 프로토콜의 산물이다

부정 결과도 평가 설계에 민감하다. 오류 탐지 정확도는 최고 모델도 52.87%였으나 오류 위치를 알려주면 틀린 추적의 교정 정확도가 +18.04~+43.92%p 올랐다(Tyen et al., 2024). 같은 오류를 외부 입력으로 바꿔 주입하면 맹점이 평균 64.5%였고 'Wait' 한 단어로 89.3% 줄었으며(Tsui, 2025), 오류의 역할 라벨만 바꿔도 교정률이 +23.3~+93.3%p 움직였다(Chen et al., 2026). 무조건 수정은 GSM8K +25.5%p에도 회복률 35.0%와 악화율 19.1%가 공존했다(Zhang, 2026).

긍정 결과도 프로토콜을 의심하게 한다. RCI·Reflexion의 오라클 정보 사용과 Self-Refine의 약한 초기 프롬프트 비교(Kamoi et al., 2024; Huang et al., 2024), 오라클 보상으로 훈련한 SCoRe(Kumar et al., 2025)는 모두 이 절의 조건 밖이다.

소결하면, 외부 근거 없는 제자리 자기수정이 정답률을 올린다는 통념은 이 조건에서 성립하지 않는다. 다만 실패의 한 원인이 오류를 찾는 능력에 있다는 점은 2절의 평가자 신뢰성과 3절의 외부 신호 결합 논의로 이어진다.

제2절 AI는 공정한 평가자인가 — 검토자가 자기 자신일 때

이 절의 질문은 생성한 모델과 같은 언어모델이 평가자가 될 때 그 판정이 사람 평가와 얼마나 일치하며 어떤 편향이 끼어드는가이다.

2.1 '사람과 80% 일치'는 지표와 과제 난이도에 따라 달라진다

높은 일치율은 지표와 비교 쌍의 난이도가 만든다. GPT-4와 전문가의 일치는 동점을 제외하면 85%로 사람끼리의 81%를 넘지만, 두 모델의 성능 차가 클수록 일치가 70%에서 거의 100%로 올라가 쉬운 비교에서만 높았다(Zheng et al., 2023). 같은 데이터를 정확도와 κ로 다시 재면 GPT-4 52.7%(κ 0.24)·ChatGPT 44.4%(κ 0.06)로 사람 평균 71.7%(κ 0.54)에 못 미쳤고(Wang et al., 2024), 21개 판정자에서 정확일치와 κ의 격차가 33.8~41.3%p에 달해 재검사 신뢰도가 높아도 타당하지 않은 판정이 공존했다(Norman et al., 2026).

과제 영역에서도 갈린다. 스토리·광고에서는 사람과 유의한 양의 Kendall τ가 나왔고(Chiang & Lee, 2023), 요약에서 G-Eval은 ρ 0.514로 앞섰으나 사람이 사람 요약을 선호할 때도 GPT-3.5 요약에 더 높은 점수를 주었으며(Liu et al., 2023), 20개 데이터셋에서는 GPT-4o도 대부분 사람 상한을 밑돌고 독성·안전에서는 음수 상관을 보였다(Bavaresco et al., 2025).

2.2 위치·장황·자기 선호 편향은 구조적이며 보정 가능성은 유형별로 갈린다

판정 뒤집힘은 구조적이다. 답의 순서만 바꿔도 판정이 뒤집히는 충돌률이 GPT-4 46.3%, ChatGPT 82.5%에 이르렀고(Wang et al., 2024), 위치 일관성은 23.8~65.0%에 그쳤으며 장황 공격에는 GPT-4만 버텐다(Zheng et al., 2023). 15개 모델에서 사람–기계 순위 일치(RBO 0.44)는 사람–사람(0.54)보다 낮았고 최대 규모 모델들은 자기 응답을 50% 넘게 선호했다(Koo et al., 2024).

자기 선호는 과제 조건에 따라 갈린다. GPT-4는 자기 출력을 73.5%로 식별했고 자기 인식을 미세조정하면 자기 선호와의 상관이 τ 0.41→0.74로 함께 올랐으며(Panickssery et al., 2024), Self-Refine을 반복할수록 자기 평가와 실제 품질의 괴리가 커져 사람 기준 편향도 19.6→21.9로 늘었다(Xu et al., 2024). 반면 10개 모

델의 '보안 질문' 테스트에서는 일반적 자기 인식 증거가 없었고 '최고 답' 전역 선호가 지배했는데, 저자들은 과제 조건 차이를 원인으로 지목한다(Davidson et al., 2024). 위치 편향은 다중증거·균형 위치 보정으로 GPT-4 62.5%(κ 0.37)까지 오르고 사람이 20%만 개입하면 73.8%로 사람 평균에 도달했으나(Wang et al., 2024), 자기 선호는 자기 인식과 함께 움직여 절차 보정의 대상이 아니며 외부 피드백을 줄 때만 줄었다(Xu et al., 2024).

2.3 검토자를 다른 분포의 모델로 바꾸면 완화된다

편향의 핵심 변수는 검토자와 생성자의 유사도다. 37개 모델·9개 벤치마크에서 검증 이득은 자기 검증에서 가장 작고 교차 패밀리 검증에서 가장 컸으며, 풀이자–검증자 유사도가 오르면 오답 수용률이 올랐다(Lu et al., 2025). GPT-3.5가 GPT-4의 답을 검토할 때가 GPT-4의 자기검토보다 나았다는 결과도 같은 방향이다(Miao et al., 2024). 사람의 일부 개입과 외부 피드백이 편향을 줄였다는 증거(Wang et al., 2024; Xu et al., 2024)까지, 완화는 모두 검토 신호를 자기 밖으로 옮기는 데서 나온다. 다만 교차 검증의 이득이 검증 가능 과제에서 컸다는 점을 열린 과제로 일반화하는 것은 추가 확인이 필요하다(Lu et al., 2025).

소결하면, 평가자가 생성자 자신일 때 '사람과 n% 일치'라는 수치만으로 평가의 신뢰를 주장할 수 없다. 완화책이 모두 검토자를 자기 밖으로 옮기는 것이라는 점이 3절의 외부 신호·사람 결합 논의로 이어진다.

제3절 외부 신호와 사람이 더해지면 무엇이 달라지는가

이 절은 같은 모델의 검토에 실행 결과·테스트·검색·도구, 사람 라벨 검증기, 다른 모델, 사람 검토가 더해질 때 무엇이 달라지는지, 그리고 사람이 더해지면 자동으로 나아지는지를 묻는다.

3.1 실행·테스트·검색·도구가 붙으면 같은 모델의 검토도 일관되게 개선된다

개선을 만드는 것은 검토 절차가 아니라 실행 가능한 근거다. 도구를 빼자 자기 비평의 효과는 QA F1 −0.03~+2.33에 그쳤으나, 검색·인터프리터 결합으로 QA F1 +7.7, TabMWP +32.3, 독성 최대값 0.353→0.171을 보였다(Gou et al., 2024). 단위 테스트를 빼면 52%로 기준 60%보다 낮아 테스트 없는 자기 성찰이 오히려 유해했으나, 테스트를 갖추면 HumanEval pass@1 91%로 GPT-4의 80%를 넘었다(Shinn et al., 2023). 실행 피드백 없는 코드 설명은 +2~3%에 머물렀으나 실행 결과는 TransCoder +12%, MBPP +8%를 가져왔고(Chen et al., 2024), 소형 모델에서도 자기 불확실성 신호로 재생성하면 6개 설정 중 5개가 하락한 반면 실행 검증 재생성은 +6.45~+25.81%p였다(Rakasi et al., 2026). 다만 MBPP의 내부 테스트 위양성 16.3%(Shinn et al., 2023)처럼 신호의 질이 개선의 상한을 정하기도 한다.

3.2 사람 라벨 검증기와 다른 모델은 효과가 있으나 신호의 질이 상한을 정한다

사람 라벨 검증기는 자기검토를 넘어서지만 상한은 신호의 질이 정한다. 사람이 단계별로 라벨한 80만 건으로 훈련한 과정 보상 모델은 모든 샘플 수에서 결과 보상 모델과 다수결을 능가했고(대표 부분집합 78.2%; Lightman et al., 2024), 사람 비평으로 훈련한 CriticGPT는 사람 비평보다 63% 선호되고 사람+모델 팀은 사람 단독보다 포괄적이고 모델 단독보다 환각이 적었으나 경쟁 프로그래밍의 정오 판별에는 유의한 도움이 없었다(McAleese et al., 2024). 같은 모델 인스턴스들의 토론은 단일 응답·자기 성찰·다수결을 능가하나 4라운

드 이상 정체되고 수렴이 정답을 보장하지 않으며(Du et al., 2024), 정보 비대칭 설정에서 토론을 본 심판은 LLM 76%, 사람 88%로 토론 없음(48%·60%)을 앞섰으나 정보가 대칭인 과제에서는 0-shot·CoT보다 낮았다(Khan et al., 2024). 교차 검토의 우위도 같은 맥락이다(Miao et al., 2024; Lu et al., 2025).

3.3 사람이 더해지는 것도 자동으로 낫지 않다 — 결과 피드백·역할 분담·오류 비상관이 조건이다

사람이 더해지는 것 자체는 개선을 보장하지 않는다. 106개 실험의 메타분석에서 사람+AI 조합은 사람·AI 중 나은 쪽보다 Hedges' g = −0.23으로 뒤졌고, 결정 과제(−0.27)가 생성 과제(0.19)보다 불리했으며, 사람이 AI보다 나을 때는 g = 0.46, 반대일 때는 −0.54로 갈렸다(Vaccaro et al., 2024). 같은 연구들을 재코딩하면 결과 피드백이 있는 연구는 14%뿐이었고, 설명만 제공하면 g = −0.31, 피드백과 설명을 함께 주면 g = 0.30이었다(Berger et al., 2026). 불일치를 사람에게 이연하는 분담에서는 사람+AI 정확도가 PRISMA 89~96%, AMSTAR 91~95%로 사람 단독 89%와 같거나 높았으나, PRECIS-2에서는 이연율이 71~76%에 달해 분담이 작동하지 않았다(Woelfle et al., 2024). 사람과 LLM의 오류가 상관되지 않을 때 둘을 섞은 집계가 더 낫다는 근거도 초록으로만 확인되었고(Eriksson et al., 2026), AI 제안을 정정하는 데 노력이 들수록 정정은 줄어 개념 오류 정정률은 31%에 그쳤다(Beck et al., 2026). 개선의 조건은 사람의 존재가 아니라 결과 피드백·역할 분담·오류 비상관이다.

소결하면, 모델 밖 신호는 검토를 일관되게 믿을 만하게 만들지만, 테스트 위양성이나 대칭 토론처럼 신호의 질이 상한을 정한다. 사람 결합도 결과 피드백·불일치의 이연·오류 비상관 같은 설계가 성립할 때 개선되며, 이 조건들이 3장 논의의 출발점이다.

제3장 논의

3.1 세 절을 관통하는 답 — 결과를 가르는 것은 검토의 횟수가 아니라 신호의 출처다

같은 모델의 내재적 자기수정은 정답을 검증할 수 있는 과제에서 대체로 정확도를 떨어뜨리거나 맞던 답을 망가뜨리고(Huang et al., 2024; Zhang, 2026), 평가자가 될 때는 자기 선호와 위치 편향이 구조적으로 끼어들며 '사람과 n% 일치'는 지표에 민감하다(Panickssery et al., 2024; Norman et al., 2026). 반면 실행·테스트·검색·도구, 사람 라벨 검증기, 다른 분포의 검토자가 더해지면 같은 실험 안의 직접 대비에서 일관되게 개선된다(Gou et al., 2024; Lightman et al., 2024; Lu et al., 2025). 그림 1이 보여주듯 결과를 가르는 조건은 검토 신호의 출처(자기 자신→다른 모델→실행·도구→사람), 과제 유형(검증 가능 과제에서는 방향이 뚜렷하고 열린 과제에서는 조건부), 검토자와 생성자의 유사도 세 가지이며, 통념은 따라서 조건부로만 성립한다.

그림 1. 검토 신호의 출처와 과제 유형에 따른 AI 자기검토의 효과

과제 유형 \ 신호 출처	① 같은 모델의 내적 자기검토	② 다른 모델·토론	③ 실행·테스트·검색·도구	④ 사람 라벨 검증기·사람 검토
정답 검증 가능 과제 (수학·코드·계획)	**악화·무효** Huang et al. 2024 (GSM8K 75.9→74.7) Stechly et al. 2024 (5%→3%) Zhang 2026 (회복 35.0% vs 악화 19.1%) — 절차 분해 시 개선: Wu et al. 2024 (75.1→87.1) Miao et al. 2024 (67.5→76.5%)	**개선** Miao et al. 2024 (GPT-3.5의 GPT-4 답 검토 > GPT-4 자기 검토) Lu et al. 2025 (교차 패밀리 이득 최대) Du et al. 2024 (토론 > 다수결) — 정보 대칭 토론은 하락: Khan et al. 2024	**개선** Gou et al. 2024 (TabMWP +32.3) Rakasi et al. 2026 (+6~+26%p) Shinn et al. 2023 (테스트 제거 시 52% < 60%)	**개선** Lightman et al. 2024 (78.2%) McAleese et al. 2024 (63% 선호, 사람+모델 팀 > 사람 단독)
열린 생성 과제 (글·요약·대화)	**조건부** Madaan et al. 2023 (5~40%p, 수학은 피드백 94% 'good') Lee et al. 2026 (자기 정제 최고 31.3%) Xu et al. 2024 (자기 편향 증폭)	**조건부** Khan et al. 2024 (정보 비대칭에서만 76% vs 48%) Du et al. 2024 (사실성 개선)	**개선** Gou et al. 2024 (독성 0.353→0.171) — 도구 없는 자기 비평은 무효 (QA F1 -0.03/+2.33)	**조건부** Vaccaro et al. 2024 (g = -0.23, 사람>AI일 때 +0.46) Berger et al. 2026 (설명만 -0.31 vs 피드백+설명 +0.30) Woelfle et al. 2024 (89~96% vs 사람 89%)

개선 악화·무효 조건부 수치는 각 논문 본문의 표·그림 기준(Rakasi·Lee·Berger는 arXiv 본문). 41편 정독.

그림 1. 검토 신호의 출처와 과제 유형에 따른 AI 자기검토의 효과. 41편의 본문 확인 수치로 구성한 4×2 조건 행렬(초록 개선, 빨강 악화·무효, 노랑 조건부).

3.2 엇갈리는 증거는 능력의 문제이기보다 측정·프로토콜·과제 조건의 문제다

엇갈림은 능력이 아니라 조건에서 온다. 계획 과제에서 Bohnet et al.(2025)의 49.8→85.5%와 Stechly et al.(2024)의 5%→3%가 정면 충돌하고, 자기 인식에서 Panickssery et al.(2024)과 Davidson et al.(2024)이 충돌하며, Self-Refine은 선호 과제에서 개선·수학에서 무효다(Madaan et al., 2023). 원인은 세 겹이다. 측정에서 집계 정확도는 회복과 악화를 섞고(Zhang, 2026), 정확일치는 κ보다 33.8~41.3%p 부풀려진다(Norman et al., 2026). 프로토콜에서는 오라클 누출과 약한 베이스라인(Kamoi et al., 2024; Huang et al., 2024), 역할 라벨과 'Wait' 한 단어가 교정률을 뒤바꾼다(Chen et al., 2026; Tsui, 2025). 과제 조건에서는 PDDL 도메인 정의 명시 여부와 과제 다양성이 갈림을 만든다. 부정 결과의 상당 부분이 측정의 산물이라면 통념을 반박하는 대신 성립 조건을 적는 것이 정직한 답이며, 오류를 찾는 능력(최고 모델도 52.87%)이 병목이고 찾기를 외부에서 도우면 고치기는 된다는 점(Tyen et al., 2024)이 세 절을 잇는 기제다.

3.3 근거의 질과 이 검토의 한계

검토한 41편 중 동료심사본은 32편, 프리프린트는 9편(2024~2026)이고, 본문을 확인한 논문은 40편, 초록만 확인한 논문은 1편(Eriksson et al., 2026)이다. 대규모 감사 연구조차 내부 수치가 어긋나 Norman et al.(2026)은 κ 디플레이션과 판정자 수를 본문과 표에서 다르게 적고 Rakasi et al.(2026)은 모델 목록이 절마다 다르므로, 이 검토는 수치를 표 단위로 확인했고 초록과 본문이 다를 때 본문을 택했다. 한계는 네 가지다. 효과량을 통합한 메타분석이 이 분야에 없어 정량 종합 대신 서술적 종합에 머문다(Vaccaro et al., 2024의 설계

가 자기수정·평가자 신뢰성에는 없음). 검색은 영어·2022~2026 중심이라 한국어 연구와 긴 실무 문서 연구는 거의 빠졌다. 벤치마크 오염과 모델 버전 변동으로 수치는 시점 의존적이다(Zhang et al., 2025). 열린 생성 과제에 오라클 없는 공정 평가 프로토콜이 없어(Lee et al., 2026도 체크리스트라는 외부 신호를 평가에 씀) 사람 일치도 축의 증거는 정답률 축보다 얇다.

제4장 결론

통념 "AI가 만든 결과물은 AI에게 다시 검토시키면 믿을 수 있다"는 조건부로만 성립한다. 같은 모델이 외부 근거 없이 제자리에서 다시 보는 검토는 정답을 검증할 수 있는 과제에서 대체로 믿을 수 없고, 같은 모델이 평가자가 되면 자기 선호와 위치 편향이 끼어들어 '사람과 n% 일치'만으로 신뢰를 주장할 수 없다. 반면 실행 결과·테스트·검색·사람 라벨 검증기처럼 모델 밖의 신호에 접지되거나 생성자와 다른 분포의 검토자를 쓸 때 검토는 일관되게 믿을 만해진다. 최종 확인의 책임은 사람에게 남지만, 사람의 검토 역시 결과 피드백과 불일치 이연 같은 설계가 있을 때만 작동한다. 필자는 같은 AI라도 두 번 보면 한 번보다 낫다고 믿고 시작했으나, 문헌을 확인한 뒤 문제가 프롬프트가 아니라 신호의 출처임을 알게 되었다. 자기 피드백은 자기 믿음을 증폭하고, 오류를 찾는 능력이 병목이며, 찾기를 밖에서 도우면 고치기는 된다. 앞으로 필요한 연구는 열린 생성 과제에서 오라클 없이 자기검토를 공정하게 평가하는 합의된 프로토콜, 피드백 출처·검토자 동일성·과제 유형을 조절변수로 둔 효과량 메타분석, 긴 실무 문서와 한국어 환경의 자기검토 연구, 모델 버전에 따른 자기수정 능력의 종단 추적과 비용 대비 이득의 체계화다.

참고문헌

Bavaresco, A., Bernardi, R., Bertolazzi, L., Elliott, D., Fernández, R., Gatt, A., Ghaleb, E., Giulianelli, M., Hanna, M., Koller, A., Martins, A. F. T., Mondorf, P., Neplenbroek, V., Pezzelle, S., Plank, B., Schlangen, D., Suglia, A., Surikuchi, A. K., Takmaz, E., & Testoni, A. (2025). LLMs instead of Human Judges? A Large Scale Empirical Study across 20 NLP Evaluation Tasks. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025)*. arXiv:2406.18403.

Beck, J., Eckman, S., Kern, C., & Kreuter, F. (2026). Bias in the Loop: How Humans Evaluate AI-Generated Suggestions. *Harvard Data Science Review, 8*(2). https://doi.org/10.1162/99608f92.0e98898d

Berger, J., Burton, J. W., Hertwig, R., Kosch, T., Kurvers, R. H. J. M., Kurzenberger, B., Lazik, C., Onnasch, L., Rieger, T., Thoma, A. I., Wulff, D. U., & Herzog, S. M. (2026). Human learning is an understudied but promising lever for boosting human–AI synergy. *Proceedings of the National Academy of Sciences, 123*(39), e2536100123. https://doi.org/10.1073/pnas.2536100123

Bohnet, B., Kamienny, P.-A., Sedghi, H., Gorur, D., Awasthi, P., Parisi, A., Swersky, K., Liu, R., Nova, A., & Fiedel, N. (2025). *Enhancing LLM Planning Capabilities through Intrinsic Self-Critique*. arXiv:2512.24103 (프리프린트).

Chen, K.-Y., Su, F.-Y., & Chiang, J.-H. (2026). *The Self-Correction Illusion: LLMs Correct Others but Not Themselves*. arXiv:2606.05976 (프리프린트).

Chen, X., Lin, M., Schärli, N., & Zhou, D. (2024). Teaching Large Language Models to Self-Debug. In *Proceedings of the 12th International Conference on Learning Representations (ICLR*

2024). arXiv:2304.05128.

Chiang, C.-H., & Lee, H.-y. (2023). Can Large Language Models Be an Alternative to Human Evaluations? In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023)*. arXiv:2305.14716.

Davidson, T. R., Surkov, V., Veselovsky, V., Russo, G. M., & West, R. (2024). Self-Recognition in Language Models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*. arXiv:2407.06946.

Du, Y., Li, S., Torralba, A., Tenenbaum, J. B., & Mordatch, I. (2024). Improving Factuality and Reasoning in Language Models through Multiagent Debate. In *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*. arXiv:2305.14325.

Eriksson, K., Karlsson, S., Vartanova, I., & Strimling, P. (2026). Large language models outperform humans at estimating society's everyday norms. *Communications AI & Computing, 1*, 15. https://doi.org/10.1038/s44488-026-00018-8

Gou, Z., Shao, Z., Gong, Y., Shen, Y., Yang, Y., Duan, N., & Chen, W. (2024). CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing. In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2305.11738.

Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). Large Language Models Cannot Self-Correct Reasoning Yet. In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2310.01798.

Kamoi, R., Zhang, Y., Zhang, N., Han, J., & Zhang, R. (2024). When Can LLMs Actually Correct Their Own Mistakes? A Critical Survey of Self-Correction of LLMs. *Transactions of the Association for Computational Linguistics, 12*, 1417–1440. https://doi.org/10.1162/tacl_a_00713

Khan, A., Hughes, J., Valentine, D., Ruis, L., Sachan, K., Radhakrishnan, A., Grefenstette, E., Bowman, S. R., Rocktäschel, T., & Perez, E. (2024). Debating with More Persuasive LLMs Leads to More Truthful Answers. In *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*. arXiv:2406.11770.

Koo, R., Lee, M., Raheja, V., Park, J. I., Kim, Z. M., & Kang, D. (2024). Benchmarking Cognitive Biases in Large Language Models as Evaluators. In *Findings of the Association for Computational Linguistics: ACL 2024*. arXiv:2309.17012.

Kumar, A., Zhuang, V., Agarwal, R., Su, Y., Co-Reyes, J. D., Singh, A., Baumli, K., Iqbal, S., Bishop, C., Roelofs, R., Zhang, L. M., McKinney, K., Shrivastava, D., Paduraru, C., Tucker, G., Precup, D., Behbahani, F., & Faust, A. (2025). Training Language Models to Self-Correct via Reinforcement Learning. In *Proceedings of the 13th International Conference on Learning Representations (ICLR 2025)*. arXiv:2409.12917.

Lee, Y.-J., Kim, S., Lee, B.-K., Moon, M., & Hwang, Y. (2026). RefineBench: Evaluating Refinement Capability of Language Models via Checklists. In *Proceedings of the 14th International Conference on Learning Representations (ICLR 2026)*. arXiv:2511.22173.

Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., Baker, B., Lee, T., Leike, J., Schulman, J., Sutskever, I., & Cobbe, K. (2024). Let's Verify Step by Step. In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2305.20050.

Liu, A., & Meng, J. (2026). *Self-Correction as Feedback Control: Error Dynamics, Stability Thresholds, and Prompt Interventions in LLMs*. arXiv:2604.22273 (프리프린트).

Liu, Y., Iter, D., Xu, Y., Wang, S., Xu, R., & Zhu, C. (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*. arXiv:2303.16634.

Lu, J., Teehan, R., Jin, J., & Ren, M. (2025). *When Does Verification Pay Off? A Closer Look at LLMs as Solution Verifiers*. arXiv:2512.02304 (프리프린트).

Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegreffe, S., Alon, U., Dziri, N., Prabhumoye, S., Yang, Y., Gupta, S., Majumder, B. P., Hermann, K., Welleck, S., Yazdanbakhsh, A., & Clark, P. (2023). Self-Refine: Iterative Refinement with Self-Feedback. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. arXiv:2303.17651.

Manakul, P., Liusie, A., & Gales, M. J. F. (2023). SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*. arXiv:2303.08896.

McAleese, N., Pokorny, R. M., Ceron Uribe, J. F., Nitishinskaya, E., Trebacz, M., & Leike, J. (2024). *LLM Critics Help Catch LLM Bugs*. arXiv:2407.00215 (프리프린트, OpenAI).

Miao, N., Teh, Y. W., & Rainforth, T. (2024). SelfCheck: Using LLMs to Zero-Shot Check Their Own Step-by-Step Reasoning. In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2308.00436.

Norman, J. D., Rivera, M. U., & Hughes, D. A. (2026). *Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias*. arXiv:2606.19544 (프리프린트).

Olausson, T. X., Inala, J. P., Wang, C., Gao, J., & Solar-Lezama, A. (2024). Is Self-Repair a Silver Bullet for Code Generation? In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2306.09896.

Panickssery, A., Bowman, S. R., & Feng, S. (2024). LLM Evaluators Recognize and Favor Their Own Generations. In *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*. arXiv:2404.13076.

Rakasi, P., Lalwani, M., Srivastava, A., Palanivel, A., Adeleke, T., Li, R., & Wu, S. (2026). *When Uncertainty Isn't Enough: An Empirical Study of Self-Correction in Code Generation*. arXiv:2608.14659 (프리프린트).

Shinn, N., Cassano, F., Berman, E., Gopinath, A., Karthik, N., & Yao, S. (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. arXiv:2303.11366.

Stechly, K., Valmeekam, K., & Kambhampati, S. (2024). On the Self-Verification Limitations of Large Language Models on Reasoning and Planning Tasks. In *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. arXiv:2402.08115.

Tsui, K.-T. (2025). *Self-Correction Bench: Uncovering and Addressing the Self-Correction Blind Spot in Large Language Models*. arXiv:2507.02778 (프리프린트).

Tyen, G., Mansoor, H., Cărbune, V., Chen, P., & Mak, T. (2024). LLMs cannot find reasoning errors, but can correct them given the error location. In *Findings of the Association for Computational Linguistics: ACL 2024*. https://doi.org/10.18653/v1/2024.findings-acl.826

Vaccaro, M., Almaatouq, A., & Malone, T. (2024). When combinations of humans and AI are useful: A systematic review and meta-analysis. *Nature Human Behaviour, 8*(12), 2293–2303. https://doi.org/10.1038/s41562-024-02024-1

Wang, P., Li, L., Chen, L., Cai, Z., Zhu, D., Lin, B., Cao, Y., Kong, L., Liu, Q., Liu, T., & Sui, Z. (2024). Large Language Models are not Fair Evaluators. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024)*. https://doi.org/10.18653/v1/2024.acl-long.511

Woelfle, T., Hirt, J., Janiaud, P., Kappos, L., Ioannidis, J. P. A., & Hemkens, L. G. (2024). Benchmarking Human-AI Collaboration for Common Evidence Appraisal Tools. *Journal of Clinical Epidemiology, 175*, 111533. https://doi.org/10.1016/j.jclinepi.2024.111533

Wu, Z., Zeng, Q., Zhang, Z., Tan, Z., & Shen, C. (2024). Large Language Models Can Self-Correct with Key Condition Verification. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP 2024)*. https://doi.org/10.18653/v1/2024.emnlp-main.714

Xu, W., Zhu, G., Zhao, X., Pan, L., & Li, L. (2024). Pride and Prejudice: LLM Amplifies Self-Bias in Self-Refinement. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024)*. https://doi.org/10.18653/v1/2024.acl-long.826

Zhang, Q., Wang, D., Qian, H., Li, Y., & Zhang, T. (2025). Understanding the Dark Side of LLMs' Intrinsic Self-Correction. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025)*. arXiv:2412.14959.

Zhang, T. (2026). *When Should LLMs Trust Their Own Revisions? A Risk-Aware Study of Intrinsic Self-Correction*. arXiv:2609.35832 (프리프린트).

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. arXiv:2306.05685.